

Facial Expressions Classification with Ensembles of Convolutional Neural Networks and Smart Voting

Rodrigo C. Moraes Elloá B. Guedes Carlos Maurício S.
Figueiredo

Universidade do Estado do Amazonas - UEA
Escola Superior de Tecnologia - EST
Laboratório de Sistemas Inteligentes - LSI

{rcm.eng, ebgcosta, cfigueiredo}@uea.edu.br


06 de Dezembro de 2019

Sumário

- 1 Introdução
- 2 Base de dados
- 3 Abordagem
- 4 Experimentos
- 5 Resultados
- 6 Trabalhos relacionados
- 7 Conclusão
- 8 Referências


Introdução

A forma **mais expressiva** com que os humanos exibem emoções é através de **expressões faciais**. Os humanos detectam e interpretam faces e expressões faciais em uma cena com **pouco ou nenhum esforço**. Ainda assim, o desenvolvimento de um sistema automatizado que realiza essa tarefa é bastante difícil [Fasel and Luetttin 2003].



Introdução - Universalidade das expressões faciais

- The Expression of Emotions in Man and Animals
 - Universalidade das expressões faciais
 - Emoções inatas
- Emoções básicas



Introdução - Aplicações

- Comportamento do consumidor
- Estudo de usabilidade
- Teste de fármacos
- Muitas outras



(a) Vitrine



Introdução

Desafio: Classificação de expressões faciais baseados em imagens estáticas *in the wild*.



(a) Felicidade



(b) Nojo



(c) Tristeza



(d) Surpresa



(e) Medo



(f) Raiva



(g) Neutro

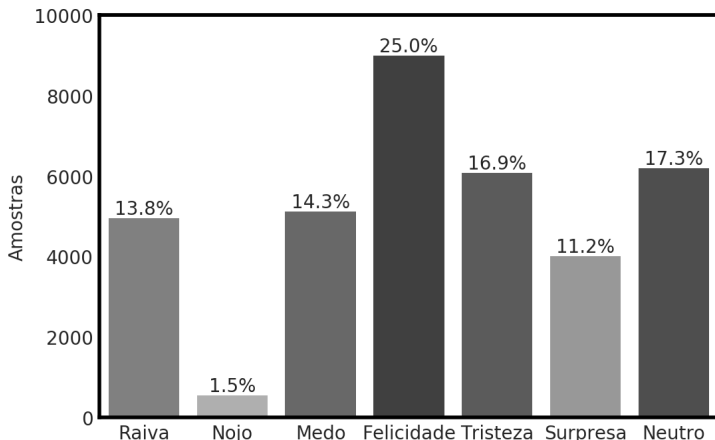
Base de dados - FER2013

- 35887 amostras
- 48 x 48, grayscale
- \pm centralizada
- \approx igualmente distribuída
- Sete categorias
 - 0 - Raiva
 - 1 - Nojo
 - 2 - Medo
 - 3 - Felicidade
 - 4 - Tristeza
 - 5 - Surpresa
 - 6 - Neutro




Figura: Facial Expression Recognition Challenge [Carrier and Courville 2013].


Base de dados - Distribuições de expressões




Base de dados - Distribuição de amostras



(a) Treinamento




(b) Validação



Abordagem

$$\begin{aligned}
 \text{Input Layer} &\Rightarrow [(\text{Convolution} \rightarrow \text{Batch Normalization}) \cdot i \\
 &\Rightarrow (\text{Pooling} \rightarrow \text{Dropout}) \cdot j] \cdot k \\
 &\Rightarrow [\text{Fully Connected} \rightarrow \text{ReLU}] \cdot \ell \\
 &\Rightarrow \text{Flatten} \Rightarrow \text{Output Layer}
 \end{aligned} \tag{1}$$



Experimentos - K-Fold

- K-Fold

1	2	3	4	5	6	7	8
		Training				PublicTest	PrivateTest
			Training				PrivateTest

Figura: Divisão de partições do K-Fold.

Experimentos - Data augmentation

- Data augmentation
 - Rotação
 - Translação
 - Escala
 - Reflexão



**Figura: Data augmentation
[Amaratunga 1970].**

Experimentos - Medidas de desempenho

- Medidas
 - F1-Score
 - Acurácia




Figura: Distribuição de emoções na base de dados.

Resultados

Tabela: Micro F1 Score de CNNs

Modelo	Micro F1 Score	Parâmetros Treináveis
1	0,689	15.250.887
2	0,676	1.778.247
3	0,660	2.134.471
4	0,679	1.778.247
5	0,666	1.189.511
6	0,678	1.780.103
7	0,694	6.653.599
8	0,628	1.186.231

Resultados

- 7 modelos especializados
- 2 modelos gerais
- 1 modelo de votação






Figura: Ensemble de Redes Convolucionais Neurais e votação inteligente.

Resultados



Resultados



Trabalhos relacionados




Tabela: Comparação entre modelo proposto com a literatura

Modelo	Acurácia
[Pramerdorfer and Kampel 2016]	75.20
[Kim et al. 2016]	73.73
[Al-Shabi et al. 2016]	73.40
Proposto	71.74
[Tang 2013]	71.20

Conclusão

- Competitivo com o estado da arte
- A estrutura de ensemble se mostrou relevante
- Relação profundidade dos modelos de CNN com a acurácia
- Trabalhos futuros
 - Aplicar outros modelos na votação inteligente
 - Fine tuning do modelo de votação

Referências I

-  Al-Shabi, M., Cheah, W. P., and Connie, T. (2016). Facial expression recognition using a hybrid cnn-sift aggregator.
arXiv preprint arXiv:1608.02833.
-  Amaratunga, T. (1970).
Using data augmentations in keras.
-  Carrier, P.-L. and Courville, A. (2013).

Referências II



Collins, M. (2008).

Exhibit review of paul ekman's photographs and work in new guinea with the south fore people examining facial expressions and emotion.



Fasel, B. and Luetttin, J. (2003).

Automatic facial expression analysis: a survey.
Pattern recognition, 36(1):259–275.



Francis-School (2018).

"google vs teacher" apakah sekolah dan guru diperlukan di zaman now?

Referências III



Kim, B.-K., Dong, S.-Y., Roh, J., min Kim, G., and Lee, S.-Y. (2016).

Fusing aligned and non-aligned face information for automatic affect recognition in the wild: A deep learning approach.
2016 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), pages 1499–1508.



Pramerdorfer, C. and Kampel, M. (2016).

Facial expression recognition using convolutional neural networks: State of the art.
CoRR, [abs/1612.02903](https://arxiv.org/abs/1612.02903).

Referências IV



Tang, Y. (2013).

Deep learning using support vector machines.

CoRR, [abs/1306.0239](#).

Agradecimentos

Obrigado

Facial Expressions Classification with Ensembles of Convolutional Neural Networks and Smart Voting

Rodrigo C. Moraes Elloá B. Guedes Carlos Maurício S.
Figueiredo

Universidade do Estado do Amazonas - UEA
Escola Superior de Tecnologia - EST
Laboratório de Sistemas Inteligentes - LSI

`{rcm.eng, ebgcosta, cfigueiredo}@uea.edu.br`